

PoC 報告 / 機械学習エンジニア

変圧器オイル温度の予測による 予防保全の価値検証

ETT データセットを用いた油温（OT）将来予測の技術検証

クライアント報告資料 / メッセージ&ボディ構成

結論：油温予測は「数時間先」で実用価値があり、予防保全への移行は十分に有望

- ① 短期(1h先)は持続予測が既に高精度（油温の自己相関 $\text{lag1}=0.99$ ）。ML の上乗せは小さく、監視自動化の基盤として堅牢。
- ② 価値の本体は 6～12h 先。持続予測が崩れる領域で LightGBM が MAE を ETTh1 約+11% / ETTh2 約+58% 改善。点検・是正のリードタイムを確保できる。
- ③ 24h 先は日次周期が支配し予測可能性が頭打ち（改善 +1%～+1%）。さらなる先読みには外気温予報など外部データが必要。
- ④ 最大のリスクは分布シフト（季節で平均油温が大きく変化）。固定閾値は不適、定期再学習が前提。

データは公開ベンチマーク（顧客実データではない）。実装は時系列リーク防止を全工程で担保。

■ 目的は「油温予測が運用・保全判断にどれだけ価値を出すか」の定量検証



検証スコープ

- 目的変数：オイル温度 OT (° C) の将来予測
- データ：ETTh1/h2 (1時間粒度・約2年) を主対象、m1/m2 で粒度差を確認
- 評価：複数ホライズン (1/6/12/24h 先) で MAE・RMSE と ベースライン比改善率(skill)
- 業務価値：高温時間帯の早期検知 (Precision/Recall) に翻訳

置いた仮定 (質問不可のため明記)


- 「 $t=T$ の特徴量を使用してよい」を、**負荷は運用計画で既知と解釈し、未来負荷を与えた上限実験**も別途実施
- 主結果は**過去情報のみ**で算出 (運用上最も安全な前提)
- 分割は時系列順 60/20/20 (シャッフル禁止)。文献の 12/4/4ヶ月分割でも傾向不変
- MAPE は OT が 0/負を取るため不採用、MAE/RMSE(° C) を採用

データは高品質だが、季節による強い非定常性（分布シフト）を持つ




- 欠損・重複なし、時刻は等間隔で単調 → 前処理リスクは小さい。
- 学習期間と評価期間で平均油温が大きく異なる**（ETTh1：train 17.3° C → test 7.7° C）。**固定閾値の監視は破綻し、相対的・適応的な基準が必要。**

油温は強い熱慣性と日次・年次の周期を持つ → 自己回帰 + 周期特徴が本質



自己相関 (熱慣性)


- 自己相関は **1h後=0.99**・**24h後=0.94** と極めて高い → **直近値 (持続予測)** が強力なベースライン。
- 時刻別・月別に明瞭な山谷 → **日次 (運転サイクル)** と **年次 (外気温)** の周期を特徴量化すべき。



時刻別・月別の平均 OT


瞬時の負荷だけでは油温を説明できない（熱は時間遅れで蓄積する）

ETTh1: OT と各負荷の同時刻相関（最大=0.22 = 弱い）



ETTh1: OT と負荷の同時刻相関

ETTh2: OT と各負荷の同時刻相関（最大=0.49 = 弱い）



ETTh2: 同（相対的に強い）

- 同時刻相関は最大でも **ETTh1 0.22 / ETTh2 0.49**。負荷→油温は**時間遅れ（積分的）**の関係。
- 示唆：負荷の現在値だけでなく**ラグ・移動統計**が効く。後述の通り未来負荷を与えても 24h 先は伸びにくい。

「厳格な時系列検証 × 差分予測」を設計の核に据えた

リーク防止（最重要）

- 時系列順分割・シャッフル禁止、境界重複なし
- 標準化統計は**train** のみで推定
- 特徴量は時刻 t 以前のみ（因果 rolling, shift $\geq$ 0）
- ハイパラ選択は TimeSeriesSplit / val で early stopping

モデル比較


- naive 持続・季節持続（ベースライン）
- Ridge（線形の目安）／**LightGBM（本命）**

設計上の意思決定：差分予測


目的を $OT(t+h)$ ではなく **変化量 $\Delta = OT(t+h) - OT(t)$** に置き、予測を $OT(t)$ に加算。

- 持続予測を錨にするため、**最悪でも naive と同等**。
- 日次サイクル等の**系統的变化のみ**を学習し改善。
- 実際、直接予測では naive に負けたが、差分予測で**全ホライズンで上回った**。

予測の価値は中期(6~12h先)で最大化し、24h先で頭打ちになる




誤差のホライズン依存



naive 比改善率(skill)

- 短期：持続予測が強く ML の上乗せは小 (ETTh1 1h=+4%)。
- 中期：持続予測が崩れる 6~12h で**改善が最大** (ETTh2 で**+58%前後**、ETTh1 で +11%前後)。
- 24h：日次周期で naive ≒ 季節持続となり、**改善は数% に収束**。

予測は妥当で、要因も解釈可能（直近変動・時刻・日平均水準・季節）



ETTh2 6h先：実測 vs 予測 vs naive

LightGBM 重要度 上位 (ETTh1, 12h先・gain)

1. sin_day (11874)
2. cos_day (6416)
3. OT_now (4062)
4. cos_year (2349)
5. OT_rstd3 (1056)
6. OT_rstd6 (1025)

短期は「直近の変動・時刻」、長期は「日平均水準・季節」が支配。物理的直感（熱慣性＋外気温）と整合し、ブラックボックスではない。

■ 高温時間帯を事前に絞り込め、点検対象の優先順位付けに使える

- テスト期間の**上位10%の高温時間帯**を 12h 先に検知する性能 (ETTh1) : **LightGBM F1=0.51** (適合率**0.47**/再現率**0.56**)、単純持続 F1=0.43。
- 用途 : 閾値超過の**事前アラート**と**点検優先度**付け。連続監視の自動化で、経験則ベースの見落とし・過検知を低減。
- 運用設計 : 誤報コストと見逃しコストに応じて**閾値を調整可能** (Precision/Recall のトレードオフを運用側が選択)。

注 : 絶対温度の閾値は分布シフトに弱いため、運用では **季節・期間で基準を更新**し、予測値ランキングと併用する設計を推奨。

工夫の要点：リーク遮断・差分予測・上限実験・データ駆動の報告

- **時系列リークの体系的遮断**を自動テスト（pytest）で恒常的に検証（未来不参照・分割整合・train限定スケーリング）。
- **差分予測**でベースライン未達を解消し、全ホライズンで naive 超え。
- **未来負荷を既知とした上限実験**で「どの情報が価値を生むか」を切り分け。
- **報告数値は metrics.json から自動注入**。コードと報告の乖離を排除（再現性）。
- **セキュリティ**：公開データのみ・秘密情報非混入・.gitignore 徹底で Public リポジトリでも情報漏洩リスクなし。

限界は明確で、次の一手も具体化できている

現時点の限界

- **24h 以上の先読みは頭打ち**（外部要因の情報不足）。
- **分布シフト**で固定閾値・固定モデルが劣化。
- 評価は単一の時系列分割（期間依存。ETTh1 の test は穏やかな期間）。
- 異常・故障ラベルが無く、保全効果は代理指標での評価。

今後の改善方針

- **外気温予報・運転計画**等の外部共変量を追加（24h+ の鍵）。
- **ローリング起点 CV + 定期再学習**で非定常に追従。
- 分位点回帰で**予測区間**を提供し、リスク判断を支援。
- 系列特化モデル（DLinear/PatchTST 等）との比較を本実装フェーズで実施。
- 実故障データと接続し、**保全 KPI（停止回避・寿命延伸）**で再評価。

付録：データ出典と再現手順

- データ：ETT (Electricity Transformer Temperature), zhouhaoyi/ETDataset (GitHub, MIT License)。Informer (AAAI 2021) で公開されたベンチマーク。
- 手法：LightGBM (Ke et al., 2017)、勾配ブースティング決定木。
- 再現：`py -3.12 -m pytest tests -q` → `src/eda.py` → `src/pipeline.py --dataset ETTh1/ETTh2` → `src/report_figures.py`。
- 本資料の数値は `reports/metrics_*.json` から自動生成。

追加データは未使用。利用する場合は出典を明記する方針。