

PoC 報告 / 機械学習エンジニア

変圧器オイル温度の予測による 予防保全の価値検証

ETT データセットを用いた油温（OT）将来予測の技術検証

クライアント報告資料 / メッセージ&ボディ構成

結論：油温予測は「中期（6～12h先）」で安定した価値を出す、24h先は頭打ち

- ① 結果は5フォールドのローリング起点バックテストで検証（単一分割の楽観を排除）。以下は naive 比改善率の 平均±標準偏差（正のフォールド数）。
- ② 中期(6～12h先)が価値の本体： ETTh2 で +54.2%±3.1% (5/5) ・ ETTh1 で +9.2%±7.7% (4/5) 改善。全/多フォールドで正 = 安定して持続予測を上回る。点検リードタイムを確保。
- ③ 短期(1h先)は持続予測が既に高精度（自己相関 lag1=0.99）。改善は ETTh1 +3.8%±1.7% (5/5)/ETTh2 +57.0%±3.2% (5/5) と堅実だが小。監視自動化の基盤。
- ④ 24h 先は予測可能性が頭打ち： ETTh1 -2.1%±5.1% (3/5) ・ ETTh2 +0.3%±5.5% (3/5) = 持続予測を安定的に超えない。先読みには外気温予報など外部データが必要。
- ⑤ 最大のリスクは分布シフト（季節で平均油温が大きく変化）→ 固定閾値は不適・定期再学習前提。

データは公開ベンチマーク（顧客実データではない）。実装は時系列リーク防止を全工程で担保し pytest で常時検証。

■ 目的は「油温予測が運用・保全判断にどれだけ価値を出すか」の定量検証



検証スコープ

- 目的変数：オイル温度 OT (° C) の将来予測
- データ：ETTh1/h2 (1時間粒度・約2年) を主対象、m1/m2 で粒度差を確認
- 評価：複数ホライズン (1/6/12/24h 先) で MAE・RMSE と ベースライン比改善率(skill)
- 業務価値：高温時間帯の早期検知 (Precision/Recall) に翻訳

置いた仮定 (質問不可のため明記)

- 「 $t=T$ の特徴量を使用してよい」を、**負荷は運用計画で既知と解釈し、未来負荷を与えた上限実験**も別途実施
- 主結果は**過去情報のみ**で算出 (運用上最も安全な前提)
- 分割は時系列順 60/20/20 (シャッフル禁止)。文献の 12/4/4ヶ月分割でも傾向不変
- MAPE は OT が 0/負を取るため不採用、MAE/RMSE(° C) を採用


データは高品質だが、季節による強い非定常性（分布シフト）を持つ



期間別 OT 分布


- 欠損・重複なし、時刻は等間隔で単調 → 前処理リスクは小さい。
- 学習期間と評価期間で平均油温が大きく異なる**（ETTh1：train 17.3° C → test 7.7° C）。**固定閾値の監視は破綻し、相対的・適応的な基準が必要。**

油温は強い熱慣性と日次・年次の周期を持つ → 自己回帰 + 周期特徴が本質




自己相関 (熱慣性)

- 自己相関は **1h後=0.99**・**24h後=0.94** と極めて高い → **直近値 (持続予測)** が強力なベースライン。
- 時刻別・月別に明瞭な山谷 → **日次 (運転サイクル)** と **年次 (外気温)** の周期を特徴量化すべき。




時刻別・月別の平均 OT

瞬時の負荷だけでは油温を説明できない（熱は時間遅れで蓄積する）



ETTh1: OT と負荷の同時刻相関



ETTh2: 同（相対的に強い）

- 同時刻相関は最大でも **ETTh1 0.22 / ETTh2 0.49**。負荷→油温は**時間遅れ（積分的）**の関係。
- 示唆：負荷の現在値だけでなく**ラグ・移動統計**が効く。後述の通り未来負荷を与えても 24h 先は伸びにくい。

「厳格な時系列検証 × 差分予測」を設計の核に据えた

リーク防止（最重要）

- 時系列順分割・シャッフル禁止、境界重複なし
- 標準化統計は**train のみで推定**
- 特徴量は時刻 t 以前のみ（因果 rolling, shift $\geq$ 0）
- ハイパラ選択は TimeSeriesSplit / val で early stopping

モデル比較


- naive 持続・季節持続（ベースライン）
- Ridge（線形の目安）／**LightGBM（本命）**

設計上の意思決定：差分予測

目的を $OT(t+h)$ ではなく **変化量 $\Delta = OT(t+h) - OT(t)$** に置き、予測を $OT(t)$ に加算。

- 持続予測を錨にするため、**最悪でも naive と同等**。
- 日次サイクル等の**系統的变化のみ**を学習し改善。
- 直接 $OT(t+h)$ 予測は naive に負けたが、差分予測で**中期まで安定して上回る**（24h は後述の通り天井）。

5フォールドのバックテストで「中期は安定して有効・24hは頭打ち」を確認




ローリング起点バックテスト：naive比改善率 mean ± std

なぜバックテストか

単一分割は評価期間に依存する (ETTh1 のtestは穏やかな期間で持続予測が強い)。起点をずらした5フォールドで mean ± std を見ることで、**再現性のある主張**に変える。

- 中期(6~12h)：ETTh2 **+54.2% ± 3.1% (5/5)**、ETTh1 **+9.2% ± 7.7% (4/5)** = 多/全フォールドで正。
- 24h：ETTh1 **-2.1% ± 5.1% (3/5)**、ETTh2 **+0.3% ± 5.5% (3/5)** = **持続予測を安定的に超えない** (単一分割の +1% は偶然)。
- 短期(1h)：堅実だが小 (ETTh1 +3.8% ± 1.7% (5/5))。

点予測に加え「予測区間」で不確実性も提示でき、要因も解釈可能



ETTh2 6h先：実測・予測・P10-P90 区間

予測区間（分位点回帰 P10/P90）

- 被覆率 6h=0.76（名目0.80）、幅は **6.4° C(6h)→9.5° C(24h)** と不確実性の増大を定量化。
- MASE(6h)：LightGBM **2.23** vs naive 5.32（基準=1段 in-sample naive。多段予測ゆえ1超は当然で、**naive を大幅に下回る**＝相対的に良好。系列間比較可）。

重要度上位（ETTh1,12h・gain）

1. sin_day (11874)
2. cos_day (6416)
3. OT_now (4062)
4. cos_year (2349)
5. OT_rstd3 (1056)
6. OT_rstd6 (1025)

短期は直近変動・時刻、長期は日平均水準・季節が支配。物理直感（熱慣性＋外気温）と整合し説明可能。

■ 高温時間帯を事前に絞り込め、点検対象の優先順位付けに使える

- テスト期間の**上位10%の高温時間帯**を 12h 先に検知する性能 (ETTh1) : **LightGBM F1=0.51** (適合率**0.47**/再現率**0.56**)、単純持続 F1=0.43。
- 用途 : 閾値超過の**事前アラート**と**点検優先度**付け。連続監視の自動化で、経験則ベースの見落とし・過検知を低減。
- 運用設計 : 誤報コストと見逃しコストに応じて**閾値を調整可能** (Precision/Recall のトレードオフを運用側が選択)。

注 : 絶対温度の閾値は分布シフトに弱いため、運用では **季節・期間で基準を更新**し、予測値ランキングと併用する設計を推奨。

工夫の要点：1発出しでなく「仮説→検証→採否」の反復で結論を固めた

- 時系列リークの体系的遮断を自動テスト（pytest 17件）で恒常検証（未来不参照・分割整合・train限定スケーリング）。
- 差分予測で直接予測のベースライン未達を解消（中期まで安定して naive 超え）。
- 5フォールド・バックテストで単一分割の楽観（24h +1%）を是正し、再現性を担保。
- 仮説を棄却する勇気：負荷の移動平均（熱蓄積）特徴を検証→ ETTh1 改善も ETTh2 悪化で 交差検証上の頑健な改善なしと判断し不採用。ハイパラ探索も現行が近最適と確認。
- 予測区間・MASE・未来負荷の上限実験を追加し、価値と限界を多面的に定量化。
- データ駆動の報告（metrics/backtest JSON から自動注入） + セキュリティ（公開データのみ・秘密非混入・機密PDF除外）。

限界はバックテストで明確化済み、次の一手も具体化できている

現時点の限界（実測に基づく）

- **24h 先は持続予測を安定的に超えない**（外部要因の情報不足。バックテストで確認）。
- **分布シフト**（季節で平均油温が大きく変化）で固定閾値・固定モデルが劣化。
- 予測区間は**やや過小被覆**（名目80%に対し0.73～0.78）。較正余地あり。
- 異常・故障ラベルが無く、保全効果は代理指標での評価。

今後の改善方針

- **外気温予報・運転計画**等の外部共変量を追加（24h+ の鍵）。
- **定期再学習** + ローリング起点 CV を運用に組み込み非定常へ追従。
- **コンフォーマル予測**で区間を較正し被覆保証を付与。
- 系列特化モデル（DLinear/PatchTST 等）との比較を本実装フェーズで実施。
- 実故障データと接続し、**保全 KPI（停止回避・寿命延伸）**で再評価。

付録：データ出典と再現手順

- データ：ETT (Electricity Transformer Temperature), zhouhaoyi/ETDataset (GitHub, MIT License)。Informer (AAAI 2021) で公開されたベンチマーク。
- 手法：LightGBM (Ke et al., 2017)、勾配ブースティング決定木。
- 再現： `py -3.12 run_all.py` (テスト→EDA→学習評価→バックテスト→図→スライド)。個別は `src/pipeline.py` / `src/backtest.py --dataset ETTh1/ETTh2`。
- 本資料の数値は `reports/metrics_*.json` と `reports/backtest_*.json` から自動生成。評価=5フォールド ローリング起点バックテスト (mean±std)。

追加データは未使用。利用する場合は出典を明記する方針。