


PoC 報告 / 機械学習エンジニア

変圧器オイル温度の予測による 予防保全の価値検証

ETT データセットを用いた油温（OT）将来予測の技術検証

クライアント報告資料 / メッセージ&ボディ構成

結論：ML の価値は変圧器の「変動性」で決まる。変動大は大きく安定、穏やかは不確実



- **変動大(ETTh2型) = 価値あり**：6～12h先で +54～57%。どの分割でも安定。
- **穏やか(ETTh1型) = 不確実**：lag1=0.99 で持続予測が強い。分割を変えると +9%↔負に振れる。資産別の事前検証が必要。
- **24h先 = 天井**：日次周期を持続予測が捕捉。外気温など外部データが要る。
- **最大リスク = 分布シフト**：季節で平均油温が変化。固定閾値は不可、定期再学習前提。

公開データのみ（顧客実データ不使用）。リーク防止は pytest 23 件で全工程検証。


■ 目的は「油温予測が運用・保全判断にどれだけ価値を出すか」の定量検証

検証スコープ

- 予測対象：油温 OT (° C) の将来値
- データ：ETTh1/h2 (1h粒度・約2年)。m1/m2 で粒度差も確認
- 評価：1/6/12/24h 先で MAE・RMSE と naive 比改善率(skill)
- 業務価値：高温時間帯の早期検知 (Precision/Recall) に翻訳



置いた仮定（質問不可のため明記）

- 「 $t=T$ の特徴量を使ってよい」→ **負荷は運用計画で既知**と解釈し上限実験も実施。主結果は**過去情報のみ**（最も安全な前提）。
- 分割は時系列順 60/20/20。文献標準 12/4/4 でも検証。
- MAPE は OT が 0/負を取るため不採用、MAE/RMSE(° C)。




予測対象：油温 OT の時系列 (ETTh1・約2年)。季節で水準が大きく動く

データは高品質だが、季節による強い非定常性（分布シフト）を持つ




- 欠損・重複なし、時刻は等間隔で単調 → 前処理リスクは小さい。
- 学習期間と評価期間で平均油温が大きく異なる**（ETTh1：train 17.3° C → test 7.7° C）。**固定閾値の監視は破綻し、相対的・適応的な基準が必要。**

油温は強い熱慣性と日次・年次の周期を持つ → 自己回帰 + 周期特徴が本質



自己相関 (熱慣性)




時刻別・月別の平均 OT

- 自己相関は **1h後=0.99**・**24h後=0.94** と極めて高い → **直近値 (持続予測)** が強力なベースライン。
- 時刻別・月別に明瞭な山谷 → **日次 (運転サイクル)** と **年次 (外気温)** の周期を特徴量化すべき。


瞬時の負荷だけでは油温を説明できない（熱は時間遅れで蓄積する）

ETTh1: OT と各負荷の同時刻相関（最大=0.22 = 弱い）



ETTh1: OT と負荷の同時刻相関


ETTh2: OT と各負荷の同時刻相関（最大=0.49 = 弱い）



ETTh2: 同（相対的に強い）

- 同時刻相関は最大でも **ETTh1 0.22 / ETTh2 0.49**。負荷→油温は**時間遅れ（積分的）**の関係。
- 示唆：負荷の現在値だけでなく**ラグ・移動統計**が効く。後述の通り未来負荷を与えても 24h 先は伸びにくい。

設計の核は「厳格な時系列検証 × 差分予測」



自己相関：1h後=0.99・24h後=0.94 → 持続予測が強敵

差分予測（設計上の意思決定）


OT(t+h) を直接当てず、**変化量** $\Delta = \text{OT}(t+h) - \text{OT}(t)$ を学習し OT(t) に加算。

- 持続予測を錨にする → **最悪でも naive 同等**、系統的变化だけ学習。
- 直接予測は naive 未達。差分予測で中期まで安定して上回る。

リーク防止／モデル

- 時系列順分割・train限定スケーリング・因果特徴 (shift $\geq$ 0)。
- ベースライン(持続/季節持続) + Ridge + **LightGBM(本命)** を比較。

5フォールドのバックテストで「中期は安定して有効・24hは頭打ち」を確認




ローリング起点バックテスト：naive比改善率 mean ± std

なぜバックテストか

単一分割は評価期間に依存する (ETTh1 のtestは穏やかな期間で持続予測が強い)。起点をずらした5フォールドで mean ± std を見ることで、**再現性のある主張**に変える。

- 中期(6～12h)：ETTh2 +**54.2% ± 3.1% (5/5)**、ETTh1 +**9.2% ± 7.7% (4/5)** = 多/全フォールドで正。
- 24h：ETTh1 **-2.1% ± 5.1% (3/5)**、ETTh2 +**0.3% ± 5.5% (3/5)** = 持続予測を安定的に超えない (単一分割の +1% は偶然)。
- 短期(1h)：堅実だが小 (ETTh1 +3.8% ± 1.7% (5/5))。

結論の頑健性を検証：ETTh2 の価値は分割に不変、ETTh1 の改善は分割依存で消える




時系列60/20/20 vs 文献Informer12/4/4 の skill

時系列分割に加え**文献標準(Informer 12/4/4)**でも評価し、結論が分割に依存しないか確認。

- **ETTh2**：両分割で 6～12h が +54～57% = **頑健**。価値の主張は信頼できる。
- **ETTh1**：時系列分割では +9% だが**文献分割では -6～-9%**に反転。 **評価期間に依存し頑健でない** = 持続予測で十分な可能性。
- 含意：**資産の変動性レジームで価値が決まる**。導入判断は 資産別・期間横断の評価が前提。

過大評価を避けるため、頑健でない改善は「不確実」と明示する方針。


なぜ効くかを説明：価値は「日内温度サイクルの振幅」で決まり、事前に予測できる



日内振幅と価値の連動／特徴量アブレーション

- **機構**：ML の価値は**日内温度サイクルの振幅**に比例。
ETTh2=9.4° C (大) → +54%、ETTh1=2.4° C (小) → +9%。24h で消えるのは**1日で一周し持続予測が捕捉**するため。
- **アブレーションで裏取り**：カレンダー（日内/季節）特徴を外すと skill が **57%→35%** に半減 = **日内サイクルが主シグナル**。負荷特徴は外しても悪化せず（無用）。
- **実務示唆 (actionable)**：導入前に**各変圧器の日内振幅を測る**だけで、ML 予測が価値を出すかを**事前にスクリーニング**できる。

点予測に加え「予測区間」で不確実性も提示でき、要因も解釈可能



ETTh2 6h先：実測・予測・P10-P90 区間

予測区間（分位点回帰 P10/P90）

- 被覆率 6h=0.76（名目0.80）、幅は **6.4° C(6h)→9.5° C(24h)** と不確実性の増大を定量化。
- MASE(6h)：LightGBM **2.23** vs naive 5.32（基準=1段 in-sample naive。多段予測ゆえ1超は当然で、**naive を大幅に下回る** = 相対的に良好。系列間比較可）。

重要度上位（ETTh1,12h・gain）

1. sin_day (11874)
2. cos_day (6416)
3. OT_now (4062)
4. cos_year (2349)
5. OT_rstd3 (1056)
6. OT_rstd6 (1025)

短期は直近変動・時刻、長期は日平均水準・季節が支配。物理直感（熱慣性＋外気温）と整合し説明可能。

誰が何のために使うか：用途は2つ。早期警報は今すぐ有効、異常検知は要追加データ

想定ユーザーと用途

運用 **運用オペレーター**：高油温の**事前警報** → 負荷抑制・冷却強化。
必要なのは MAE でなく h時間前の検知率と低誤報。

保全 **信頼性技師／設備管理**：劣化・異常の**早期検知**（予防保全の本丸）。期待温度からの残差で兆候を捉える。


計画 **保全計画担当**：点検の**優先順位付け**（リスクランキング）。

検証の結論（用途別）

- ① **早期警報** = **今すぐ有効**。変動大の変圧器で実証済（次スライド）。
- ② **異常検知** = **今のデータでは不足**。早期警報に最適な自己回帰モデルは故障を**追従吸収**し検知不能。ソフトセンサが正解だが外気温データが要る。
- → **段階導入**：まず早期警報、異常検知はフェーズ2（外部データ取得後）。

MAE でなく **用途別の性能指標** で検証したのが要点。


実証：早期警報は6h前に検知率3倍・誤報週1件未満／自己回帰は故障の98%を吸収



用途①早期警報の検知率／用途②合成故障への残差

- **用途①早期警報(ETTh2)：**高温(閾値45° C)を **6h前に再現率62%・適合率83%・誤報0.58件/週**。持続予測は再現率20% (先読み不可)。
- **用途②異常検知：**合成故障(+6° Cドリフト)のうち 残差に現れる量 = **自己回帰2% (吸収し検知不能)、ソフトセンサ68%** (反応するがSN比0.85で実用不足)。
- **含意：**用途で最適モデルが異なる。予防保全には外気温 + 熱モデルが必要。

モデル選択も検証：勾配ブースティングが総合最良、深層 DLinear が穏やか資産で拮抗




Ridge/LightGBM/MLP/DLinear を同一の差分予測で比較（5フォールド平均）

全モデルを同じ差分予測に統一し、モデルの差だけを5フォールドで比較。

- **LightGBM が総合最良**：ETTh2 で +57% (h6) と最高、ETTh1 でも安定して正。表形式・非線形・少データに強く本命として妥当。
- **DLinear（系列分解+線形, AAI2023）は穏やかな ETTh1 で逆に最良**（h6 +14% > LightGBM +9%）。日内サイクルが支配的な資産では生波形の線形分解が効く。
- **MLP は過学習で全敗**（多くで負）。データ規模に対し過剰。
- 含意：資産レジームで最適モデルも変わる→本実装は両者を持ち選択/アンサンブル。

強化学習は不採用：本タスクは入力→将来値の 教師あり回帰。RL（逐次意思決定）が活きるのは予測を踏まえた**下流の制御**であり PoC 範囲外。

特徴量は「増やすほど良い」ではない：穏やか資産は増で改善、変動資産は40前後が最適




最小16 / 現行40 / 拡張110 特徴量の skill (6/12h平均)

特徴量を最小・現行・拡張の3水準で5フォールド比較し、過不足を検証した。

- **ETTh2 (変動大) は逆U字**：現行40で最良(+57%)、110に増やすと+55%へ悪化＝過学習。
- **ETTh1 (穏やか) は単調改善**：16→40→110 で +4→+9→+13%。シグナルが弱く**多特徴が効く**。
- **採用＝現行40**：両レジームで頑健な妥協点。一方を伸ばす拡張は他方を壊すため、**YAGNI＋頑健性**でこの水準を選択（負荷移動平均を棄却した判断と整合）。

限界を改善：split-conformal で予測区間の過小被覆を名目80%まで較正



分位点回帰 (旧) vs split-conformal (改善) の実測被覆率

分位点回帰の区間は系統的に過小被覆だった。検量(val)集合の残差分位点で幅を決める **split-conformal** で較正した。

- 被覆率を名目**0.80**へ回復：6h 0.74→ **0.79**、24h 0.76→ **0.80**。幅は同等～微増で済む。
- 分布のずれた検証期間でも**被覆保証を実務的に確保**。運用時の「区間の信頼性」を担保できる。
- 時系列で交換可能性は厳密に成り立たないため、**直近窓での再較正**を運用に組込む前提。

限界スライドで挙げた「過小被覆」を本実装で解消済み。

工夫：1発出しせず「仮説→検証→採否」を反復して結論を固めた

- **リーク遮断を自動テスト化**（pytest 23件）。加えてノイズ下限・故意リーク検出・指標の独立再計算で「漏洩なし」を確認。
- **差分予測**で直接予測の baseline 未達を解消し、中期まで naive 超え。
- **過大評価を避ける検証**：バックテスト・分割感度・シード・アブレーションで、結論を「変動性レジーム依存」へ正直に修正。
- **効かない仮説は棄却**：負荷の移動平均特徴は交差検証で改善なく不採用。
- **再現性とセキュリティ**：数値は JSON から自動注入、公開データのみ・機密PDF除外。

限界はバックテストで明確化済み、次の一手も具体化できている

現時点の限界（実測に基づく）

- 穏やかな資産(ETTh1)では価値が評価期間依存で頑健でない（分割で符号反転）。
- 24h 先は持続予測を安定的に超えない（外部要因の情報不足。全分割で確認）。
- 分布シフト（季節で平均油温が大きく変化）で固定閾値・固定モデルが劣化。
- 予測区間は分位点回帰だと過小被覆（名目80%対fold平均0.74）だったが、**split-conformal** で名目80%へ較正済（前スライド）。残る課題は分布シフト下の再較正運用。
- **データ品質**：ETTm2 は OT の張り付き（連続同値）が**21.7%** = センサ固着/前値補完の疑い。実データでは品質検証が前提。
- 異常・故障ラベルが無く、保全効果は代理指標での評価。

今後の改善方針

- **外気温予報・運転計画**等の外部共変量を追加（24h+ の鍵）。
- **定期再学習** + ローリング起点 CV を運用に組み込み非定常へ追従。
- **コンフォーマル予測**で区間を較正（本PoCで実装済）→ 分布シフト追従の再較正を運用化。
- 系列特化モデル（DLinear を実装・比較済、ETTh1で最良）→ PatchTST 等へ拡張、レジーム別に選択。
- 実故障データと接続し、**保全 KPI（停止回避・寿命延伸）**で再評価。

付録：データ出典と再現手順

- データ：ETT (Electricity Transformer Temperature), zhouhaoyi/ETDataset (GitHub, MIT License)。Informer (AAAI 2021) で公開されたベンチマーク。
- 手法：LightGBM (Ke et al., 2017)、勾配ブースティング決定木。
- 再現：`py -3.12 run_all.py` (テスト→EDA→学習評価→バックテスト→分割感度→図→スライド)。個別は `pipeline / backtest / split_sensitivity / verify_all / business_eval / model_compare / feature_sensitivity / conformal`。
- DLinear: Zeng et al., "Are Transformers Effective for Time Series Forecasting?", AAAI 2023。コンフォーマル: Vovk et al. / split-conformal (検量集合の残差分位点で被覆保証)。
- 本資料の数値は `reports/metrics_*.json` と `reports/backtest_*.json` から自動生成。評価=5フォールド ローリング起点バックテスト (mean±std)。

追加データは未使用。利用する場合は出典を明記する方針。